UNIVERSIDAD DE GUAYAQUIL

FACULTAD DE CIENCIAS, MATEMATICAS Y FISICAS

CARRERA DE SOFTWARE

MATERIA:

APLICACIONES DISTRIBUIDAS

TEMA DE ACTIVIDAD:

NVIDIA

DOCENTE:

CALDERON GAVILANES MARLON ADRIAN

ESTUDIANTE:

TENESACA PINCAY CINTHIA MARIA

CICLO ESCOLAR:

2025 – 2026 CICLO 2

INDICE

1. Modelo de ejecución de CUDA 1

1.1. Hilos 1

1.2. Bloques 1

1.3. Grids 1

2. Comparación 2

3. Caao de uso real 2

4. Reflexiona 3

CUDA

Nvidia creó un entorno de desarrollo llamado CUDA para aprovechar al máximo la potencia de estas potentes CPU. Este entorno de desarrollo es uno de los favoritos entre los profesionales de la inteligencia artificial, el análisis de datos y la ciberseguridad.

La Arquitectura Unificada de Computación (CUDA) es una plataforma para el procesamiento de propósito general en las GPU de Nvidia. Las tareas que no requieren ejecución secuencial pueden ejecutarse en paralelo con otras tareas en la GPU mediante CUDA. Gracias a la compatibilidad con los lenguajes C, C++ y Fortran, es extremadamente fácil transferir tareas de computación intensiva a la GPU de Nvidia mediante CUDA. CUDA se utiliza en ámbitos que requieren una gran potencia de cálculo o en escenarios donde la paralelización es posible y se requiere un alto rendimiento que la permita. Ámbitos como el aprendizaje automático, la investigación y el análisis de ciencias médicas, física, supercomputación, minería de criptomonedas, modelado científico y simulaciones, entre otros, utilizan CUDA.

1. Modelo de ejecución de CUDA

1.1.Hilos

La unidad más pequeña de ejecución. Cada hilo ejecuta el kernel y se identifica por un índice único (threadIdx) dentro de su bloque, lo que le permite procesar una parte específica de los datos.

1.2.Bloques

Un conjunto de hilos que pueden cooperar entre sí, compartir datos a través de memoria compartida y sincronizarse (__syncthreads()). Los bloques se organizan en 1, 2 o 3 dimensiones y se identifican por blockIdx.

1.3.Grids

La estructura superior que contiene todos los bloques de una misma ejecución de kernel. Permite escalar el procesamiento a miles de hilos, superando el límite de hilos por bloque.

2. Comparación

CPU	GPU
- Construida con miles de millones de transistores, la unidad central de procesamiento (CPU) puede tener varios núcleos y comúnmente se la conoce como el "cerebro" de la computadora - Es esencial para todos los sistemas informáticos modernos, ya que ejecuta las órdenes y los procesos que necesitan la computadora y el sistema operativo. - La CPU también es importante para determinar la rapidez con que los programas pueden ejecutarse mientras realizan tareas como navegar por internet, hacer cálculos de física para juegos y otros programas o crear hojas de cálculo	- La unidad de procesamiento de gráficos (GPU) tiene muchos núcleos más pequeños y especializados - Estos núcleos ofrecen un enorme desempeño al trabajar juntos y dividir las tareas de procesamiento entre muchos núcleos simultáneamente (o en paralelo) - La GPU se destaca en tareas altamente paralelas, como renderizar imágenes durante un juego, manipular datos de video durante la creación de contenido y calcular resultados en cargas de trabajo de IA intensivas. -

3. Caao de uso real

En el artículo *Performance of Medical Image Processing Algorithms Implemented in CUDA running on GPU based Machine*, los autores implementan y evalúan **algoritmos de procesamiento de imágenes médicas** utilizando GPUs con la plataforma **CUDA** para acelerar tareas que de otro modo serían muy lentas en CPU. El estudio incluye técnicas de análisis de volúmenes de imágenes médicas y demuestra mejoras significativas en el rendimiento basado en la paralelización de operaciones complejas sobre la GPU. (Kalaiselvi, Sriramakrishnan, & Somasundaram, 2018)

CUDA es adecuada porque permite descomponer tareas de procesamiento de imágenes —como filtrado, segmentación y análisis volumétrico— en miles de cálculos que se ejecutan simultáneamente en una GPU. Esto transforma tareas que en CPU tomarían minutos u horas en procesos que pueden completarse en segundos o milisegundos, especialmente críticas para aplicaciones médicas en tiempo real.

Las operaciones sobre matrices y volúmenes de datos que se encuentran en el procesamiento de imágenes (por ejemplo, convoluciones y transformaciones espaciales) son intrínsecamente paralelizables. CUDA está diseñada para explotar esta paralelización

a nivel de hardware con miles de núcleos de propósito general y una alta memoria de ancho de banda, lo cual mejora dramáticamente el rendimiento respecto a la CPU.

La mayoría de los frameworks de **IA y aprendizaje profundo** (como TensorFlow o PyTorch) utilizan CUDA y bibliotecas como **cuDNN** y **cuBLAS** para acelerar operaciones internas cuando entrenan y ejecutan modelos de visión por computadora —muy usados en clasificación, segmentación y análisis de imágenes médicas—. Esto permite que los algoritmos desarrollados en investigación puedan escalar a entornos de producción.

Plataformas de IA médica como las integradas en sistemas de reconstrucción de imágenes o segmentación avanzada ya utilizan GPU acelerada con CUDA para ofrecer diagnósticos más rápidos y precisos, reduciendo tiempos de espera de pacientes y mejorando la eficiencia clínica.

4. **Reflexiona**

- **¿En qué tipo de problemas NO sería recomendable usar CUDA?**

CUDA no es recomendable para problemas inherentemente secuenciales o con baja paralelización, donde las GPUs ofrecen poco o ningún beneficio sobre CPUs y generan overhead innecesario.

Tareas como algoritmos recursivos simples (e.g., Fibonacci secuencial), lógica de control ramificada o procesamiento de datos con dependencias estrictas entre pasos, ya que los núcleos CUDA están optimizados para ejecución concurrente masiva, no para flujos lineales. En estos casos, el tiempo de transferencia de datos CPU-GPU y la sincronización superan cualquier ganancia potencial.

Para operaciones con volúmenes de datos mínimos (e.g., matrices de 10x10 o cálculos unitarios), el overhead de inicialización de kernels y memoria CUDA hace que sea más lento que en CPU, sin aprovechar el paralelismo masivo.

Bibliografía

¿Qué es CUDA de NVIDIA y cómo se utiliza en ciberseguridad? (17 de Noviembre de 2025). Obtenido de HACKER ARISE: https://hackers-arise.com/what-is-nvidias-cuda-and-how-is-it-used-in-cybersecurity/

CPU o GPU: ¿cuál es la diferencia? (s.f.). Obtenido de intel: https://www.intel.la/content/www/xl/es/products/docs/processors/cpu-vs-gpu.html

CUDA. (s.f.). Obtenido de INCREDIBUILD: https://www.incredibuild.com/integrations/cuda

Kalaiselvi, T., Sriramakrishnan, P., & Somasundaram, K. (8 de Enero de 2018). *Performance of Medical Image Processing Algorithms Implemented in CUDA running on GPU based Machine*. Obtenido de Modern Educaction and Computer Sciene : https://www.mecs-press.org/ijisa/ijisa-v10-n1/v10n1-7.html?utm_source=chatgpt.com