UNIVERSIDAD DE GUAYAQUIL

FACULTAD DE CIENCIAS, MATEMATICAS Y FISICAS

CARRERA DE SOFTWARE

MATERIA:

APLICACIONES DISTRIBUIDAS

INVESTIGACION

TEMA DE ACTIVIDAD:

ESTRUCTURA DE PROYECTOS

DOCENTE:

CALDERON GAVILANES MARLON ADRIAN

ESTUDIANTE:

TENESACA PINCAY CINTHIA MARIA

CICLO ESCOLAR:

2025 – 2026 CICLO 2

INTEGRACION DE MODELOS DE INTELIGENCIA ARTIFICAL LIGER DENTRO DE UNA ARQUITECTURA DE MICROSERVICIOS

El crecimiento de los sistemas distribuidos modernos ha impulsado la necesidad de arquitecturas capaces de procesar información en tiempo real, adaptarse a cambios dinámicos y operar de forma autónoma. La integración de inteligencia artificial ligera dentro de microservicios se ha vuelto clave para este tipo de sistemas, permitiendo ejecutar inferencias directamente en dispositivos embebidos o complementarlas con servicios de IA en la nube.

La IA ligera, representada por TinyML y modelos optimizados, permite trasladar capacidades de decisión al borde de la red, reduciendo la latencia, el consumo de energía y el uso de ancho de banda. Por otro lado, la IA en la nube proporciona modelos más grandes y potentes para tareas intensivas. La combinación de ambos enfoques en un ecosistema de microservicios crea sistemas altamente eficientes, resilientes y autónomos.

TinyML se refiere a la ejecución de modelos de aprendizaje automático extremadamente ligeros en microcontroladores y dispositivos de bajo consumo. Estos modelos están optimizados mediante técnicas como cuantización, poda o distilación de conocimiento, permitiendo la inferencia en espacios de memoria reducidos.

La ***nube*** ofrece infraestructura flexible para entrenar, alojar y orquestar modelos de IA complejos, soportando grandes volúmenes de datos y procesamiento. Su integración en arquitecturas híbridas permite complementar las capacidades locales.

MICROSERVICIOS

Los ***microservicios*** son componentes pequeños, independientes y desplegables de manera autónoma que se comunican entre sí mediante APIs ligeras. En aplicaciones de tiempo real, estos servicios deben coordinarse para procesar eventos con baja latencia mientras escalan dinámicamente.

1.1.Microservicios con inferencia local (On-Device AI)

Los dispositivos embebidos pueden ejecutar modelos TinyML para procesar datos localmente. Estos microservicios pueden:

- Detectar eventos en tiempo real.
- Reducir la frecuencia de transmisión de datos.

- Enviar únicamente alertas o embeddings relevantes

1.2.Microservicios con inferencia en el borde (Edge AI)

Gateways o dispositivos edge pueden ejecutar modelos más complejos usando TensorFlow Lite, ONNX Runtime Mobile u otros runtimes optimizados. Funcionan como servicios intermedios entre dispositivos TinyML y la nube.

1.3.Microservicios con inferencia en la nube

Permiten ejecutar modelos pesados de IA que requieren procesamiento intensivo, como análisis predictivo, procesamiento de múltiples flujos de datos o ejecución de modelos de deep learning no aptos para dispositivos embebidos.

ARQUITECTURA HÍBRIDA BASADA EN IA LIGERA

La arquitectura propuesta combina tres niveles:

1. ***Nivel de dispositivo (TinyML):*** decisiones rápidas y autónomas.
2. ***Nivel de borde:*** agregación, inferencias extendidas y control local.
3. ***Nivel de nube:*** entrenamiento, análisis complejos y orquestación global.

Esta arquitectura permite:

- Latencias mínimas.
- Reducción del tráfico hacia la nube.
- Mayor resiliencia ante fallos de conectividad.
- Despliegue incremental y escalable.

COMUNICACIÓN Y COOPERACIÓN ENTRE MICROSERVICIOS INTELIGENTES

Los microservicios colaboran mediante:

- MQTT para dispositivos embebidos.
- gRPC para bajas latencias entre servicios.
- REST para compatibilidad.
- Colas de mensajes (Kafka, RabbitMQ) para flujos continuos.

Los modelos se convierten en componentes autónomos capaces de:

- Tomar decisiones sin intervención humana.

- Ajustar parámetros en tiempo real.
- Activar procesos en cascada dentro del sistema.

AUTOMATIZACIÓN Y OPTIMIZACIÓN EN SISTEMAS DISTRIBUIDOS

La IA integrada en microservicios permite:

- Monitoreo inteligente de recursos.
- Autoescalado basado en eventos.
- Predicción de fallas y mantenimiento preventivo.
- Balanceo dinámico de cargas usando IA.
- Optimización del consumo energético.

DESAFÍOS Y CONSIDERACIONES

- Seguridad en la distribución de modelos.
- Gestión del versionado de modelos en producción.
- Protección de datos sensibles.
- Monitoreo continuo de la precisión de los modelos.
- Gestión de fallos en entornos híbridos.

Para finalizar, la combinación de modelos de inteligencia artificial ligera y microservicios permite diseñar sistemas distribuidos más eficientes, autónomos y escalables. TinyML habilita decisiones inmediatas en el borde, mientras que los microservicios en la nube coordinan tareas complejas, equilibrando capacidad computacional y latencia. La integración adecuada de estas tecnologías representa un avance significativo para aplicaciones en tiempo real que demandan alta disponibilidad, bajo costo operativo y autonomía inteligente.

Bibliografía

Dilmegani, C. (27 de Septiembre de 2025). *TinyML (EdgeAI): Aprendizaje automático en el borde*. Obtenido de IA Múltiple: https://research.aimultiple.com/tinyml/

Ghahramani, Z. (27 de Mayo de 2015). *Aprendizaje automático probabilístico e inteligencia artificial*. Obtenido de nature: https://www.nature.com/articles/nature14541

Lewis, J., & Fowler, M. (25 de Marzo de 2014). *Microservicios: Una definición de este nuevo término arquitectónico*. Obtenido de martinfowler: https://martinfowler.com/articles/microservices.html

TinyML: la nueva tendencia IA que dominará el mercado. (18 de Julio de 2024). Obtenido de inesdi: https://www.inesdi.com/blog/TinyML/

Warden, P. (Diciembre de 2019). *TinyML*. Obtenido de O'Reilly: https://www.oreilly.com/library/view/tinyml/9781492052036/